BBC

Test miARN pour diagnostiquer le cancer de la prostate à partir de l'urine

Rappel – But du projet

- Comprendre le contexte (prostate et micro-ARN)
- Comprendre les données micro-arrays reçues
- Développer un modèle statistique de diagnostique avec les données reçues

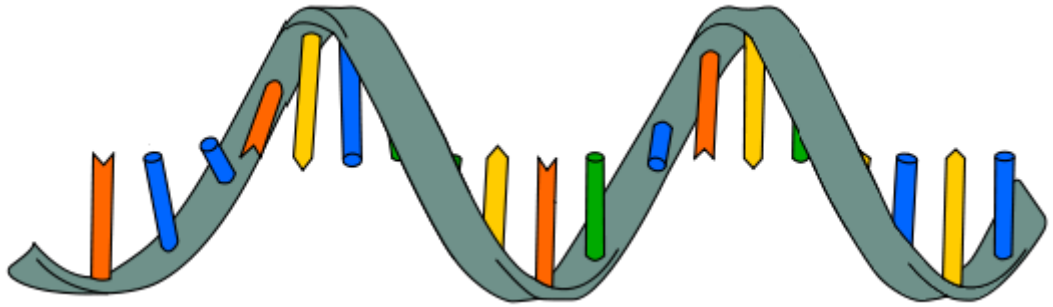

Démarche d'analyse

- Analyse des fichiers *matrix* et *soft*
- Extraction et formatage des données
- Etude de la corrélation entre Sains et PCa
- Sélection utilisant la p-value de chaque corrélation
  - Essais avec le t-test -> inutile dans notre cas
- Entrainement des modèles -> résultats moyens
- Amélioration du set en testant les micro-ARN 2 par 2
  - Les modèles donnent des résultats bien mieux

Analyse des fichiers

- Fichier *matrix*
  - *60 patients*
  - *Une dizaine de patients sains*
  - *Niveau d'expression de plus de 20'000 micro-ARN*
  - *Données principales étudiées*
- Fichier *soft*
  - *Intensité observée sur chaque micro-ARN*
  - *P-value des valeurs présentes*
  - *Utilisé à des fins de vérification*

Extraction et formatage des données

- Classification des types de patients (malade ou non)
- Séparer les données en test-set et train-set

Corrélation

- Calcul de la corrélation entre les données et un profil désiré

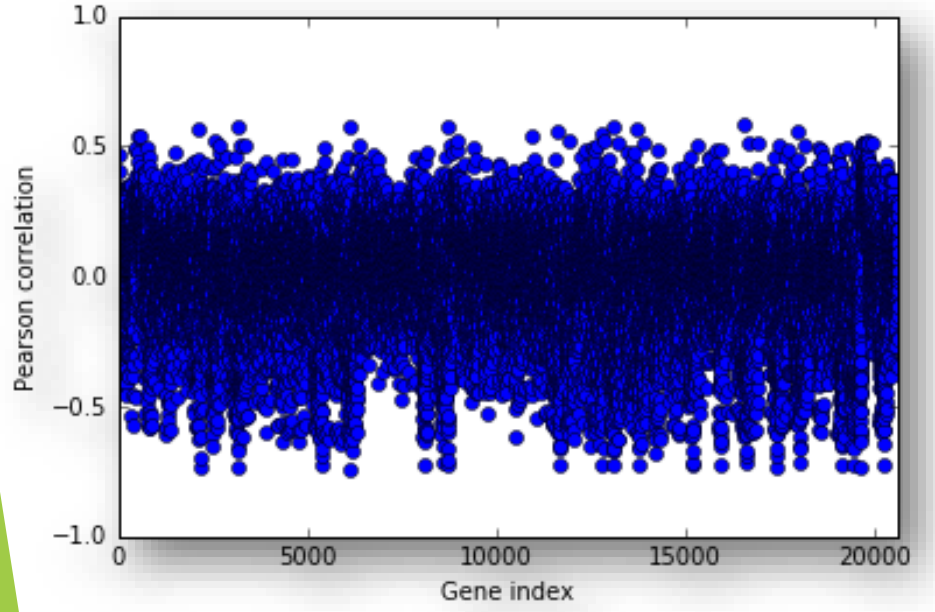

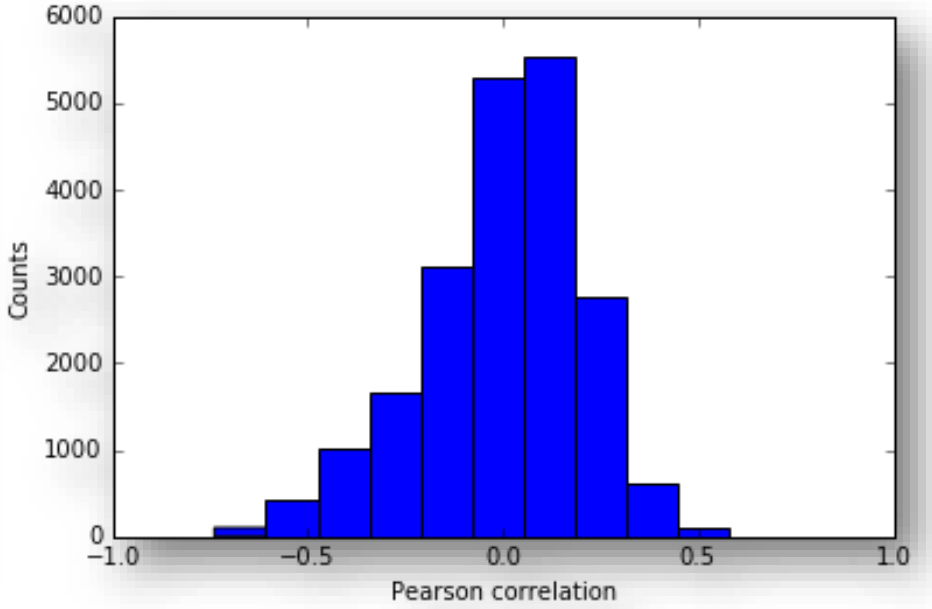

Comparaison avec un set aléatoire

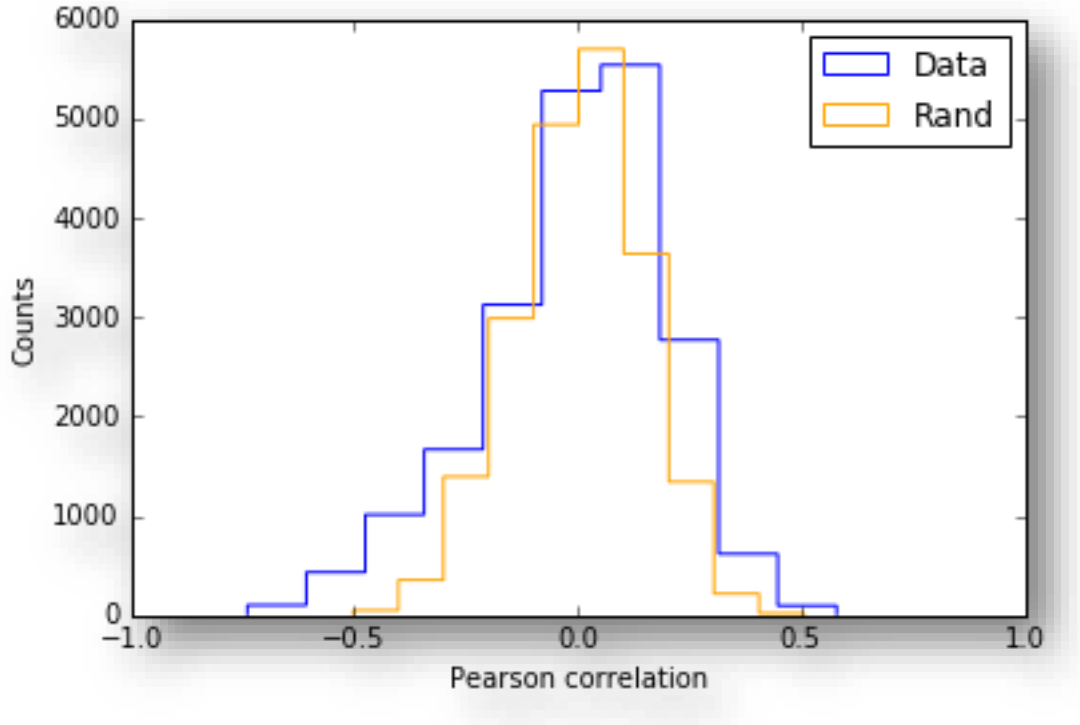

Sélection des micro-ARN

- Nous choisissons ceux dont la corrélation est la plus significative
  - P-value la plus petite -> moins de chance d'être dû au hasard

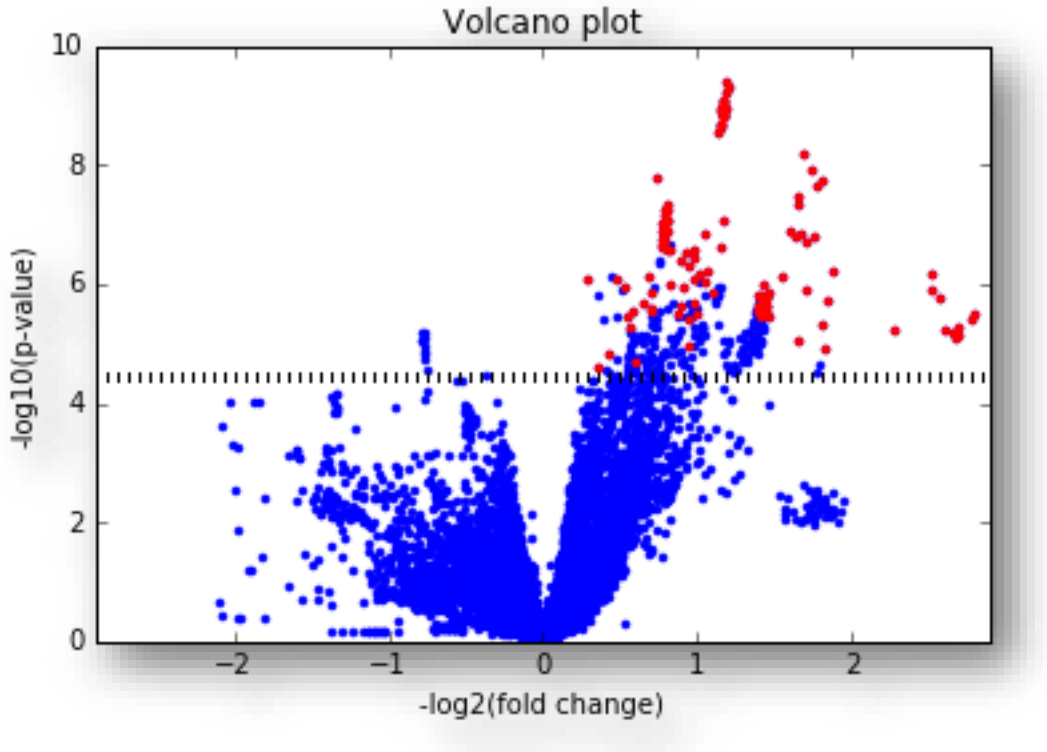

Entrainement des modèles

- Tests avec plusieurs classificateur
  - kNN 71%
  - SVM 71%
  - Random Forest 71%

Résultats très moyens, peut mieux faire !?

Amélioration du data set

- On calcule avec kNN les scores de réussite avec chaque paire des 60 micro-ARN précédemment sélectionnés
- On prend les micro-ARN qui ont la somme des scores la plus élevée

Résultats

- On obtient une nette amélioration tout en réduisant le nombre de micro-ARN nécessaires à 20
  - kNN: 85%
  - SVM: 71%
  - Random Forest: 85%

Seul SVM ne s'améliore pas, les autres donnent des résultats stables à 85%.

Vérification des résultats

- Dummy estimator
  - Avec des micro-ARN sélectionnés au hasard, nous obtenons environ 73% de résultats corrects
  - Si on prend le maximum de score réalisé par le dummy estimator on obtient des résultats environ entre 20% et 100% -> **c'est là qu'on se sent mal**
- Fichier soft
  - Contient des p-values différentes
  - En sélectionnant les micro-ARN d'après ces valeurs, on obtient des valeurs inférieures à nos précédent tests

Conclusion…

- Nous ne sommes pas sûr d'avoir trouvée quoi que ce soit de significatif étant donné qu'un dummy estimator donne des 100%
- Soit c'est un véritable hasard sans réelle corrélation, soit nos calculs ne sont pas totalement corrects

… ou pas

- En voyant ces résultats on s'est dit qu'on pouvait bien changer quelque chose
  - On ne met que des malades dans le test-set
- Conséquences
  - Les calculs utilisent le double de micro-ARN (126 au lieu de 60)
  - Tous les classificateurs donnent 100% de résultats juste avant même d'avoir comparé les micro-ARN par paires
    - Après réduction du set donnée à 20 micro-ARN seul kNN ne donne que 87% de juste
- Le dummy estimator donne toujours des très bon résultats (95% de résultats justes)

Conclusion

- Il est difficile de travailler avec ces données
  - Beaucoup de dépendance à la construction du test-set
  - On obtient de meilleurs résultats en ne mettant que des malades pour les tests
  - Les données aléatoires donnent d'excellents résultats
- Les bases mathématiques sont nouvelles pour nous
  - On se perds vite dans les différentes notions
  - Difficile de savoir quoi faire pour améliorer les résultats

Questions ?